

Inteligência Artificial na Detecção e Prevenção de Ameaças

Ithalo Rannieri¹, Lorena C. Branco¹, Maria E. Carvalho, Thiago L. Santos¹, Victor Conde¹

¹Centro de Informática - Universidade Federal de Pernambuco (UFPE)
Caixa Postal 7.851 - 50.732-970 - Recife - PE - Brasil

iras@cin.ufpe.br, lccb2@cin.ufpe.br, mecb@cin.ufpe.br, tfls@cin.ufpe.br,
vddc@cin.ufpe.br

Abstract. *The rise of cyberattacks and the global expansion of cybercrime underscore the limitations of traditional defense mechanisms, which struggle to address threats such as zero-day exploits and polymorphic malware. This gap persists because most security solutions still operate reactively, with limited ability to continuously adapt to evolving attack patterns. In this context, Artificial Intelligence (AI) has emerged as a promising approach to enhance cybersecurity, enabling supervised and unsupervised Machine Learning techniques to proactively detect anomalies and automate incident analysis and response. This article examines modern AI-driven defense architectures, including multilayer models and the Zero Trust Architecture, while also discussing critical challenges such as adversarial machine learning, data bias, and the need for model explainability. In addition, we analyze emerging trends, including generative AI, human-machine collaboration in intelligent SOCs, and the growing relevance of cyber-resilience in safeguarding digital ecosystems. In conclusion, the study offers insights into how AI-based strategies can support more adaptive and resilient cybersecurity frameworks.*

Resumo. *O aumento de ataques e o crescimento do cibercrime global evidenciam as limitações das defesas tradicionais, que não conseguem lidar adequadamente com ameaças como ataques zero-day e malware polimórfico. Essa lacuna persiste porque a maioria dos mecanismos de defesa ainda opera de modo reativo, com baixa capacidade de adaptação contínua, o que os torna incapazes de acompanhar a sofisticação e a variabilidade dos ataques modernos. Nesse contexto, a Inteligência Artificial (IA) surge como um recurso promissor para fortalecer a cibersegurança, permitindo que técnicas de Machine Learning supervisionado e não supervisionado detectem anomalias de forma proativa e automatizam a análise e a resposta a incidentes. Este artigo examina arquiteturas modernas de defesa baseadas em IA, incluindo modelos multicamadas e o conceito de Zero Trust Architecture, além de discutir desafios relevantes como adversarial machine learning, viés de dados e a necessidade de explicabilidade dos modelos. Também são analisadas tendências emergentes, como o uso de IA generativa, a cooperação humano-máquina em SOCs inteligentes e a crescente importância da ciber-resiliência na proteção de ecossistemas digitais.*

1. Introdução

A segurança de redes tornou-se prioridade estratégica em um mundo digitalizado, onde a transformação tecnológica, apesar de trazer agilidade operacional, ampliou exponencialmente a superfície de ataque. Segundo o relatório publicado pela

Cybersecurity Ventures, os custos globais com crimes cibernéticos devem atingir US\$12,2 trilhões anuais até 2031 [Braue 2025], evidenciando a urgência de soluções mais eficazes.

Ameaças como o *malware* polimórfico, *phishing* direcionado, ataques distribuídos de negação de serviço (DDoS) e *ransomware-as-a-service* (RaaS) tornaram-se não apenas mais frequentes, mas significativamente mais sofisticadas. Técnicas de evasão avançadas, como ofuscação de código e criptografia de *payloads*, permitem que atacantes contornem defesas baseadas em assinaturas e regras estáticas, pilares das soluções tradicionais de segurança [Braue 2025].

Diante desse cenário, abordagens convencionais que dependem de bases de dados de ameaças conhecidas e análise reativa mostram-se insuficientes para detectar ataques *zero-day* e variantes de *malware* nunca antes catalogadas [Fatemeh e Abadi 2023]. A Inteligência Artificial (IA) e o *Machine Learning* (ML) emergem, portanto, como tecnologias disruptivas capazes de oferecer detecção proativa e adaptativa.

Neste contexto, este trabalho apresenta uma visão geral sobre o uso da IA na cibersegurança, com o objetivo de analisar como técnicas de ML e modelos inteligentes vêm sendo aplicados na detecção, prevenção e resposta a ameaças digitais. Este estudo busca evidenciar o papel da IA como elemento transformador das estratégias de defesa, destacando tanto seus benefícios em termos de automação e precisão quanto os desafios associados à sua adoção. Além disso, o artigo discute arquiteturas modernas de segurança baseadas em IA, bem como tendências emergentes que apontam para uma integração cada vez mais estreita entre a IA, análise comportamental e a ciber-resiliência organizacional.

Em particular, este paper apresenta que por meio de algoritmos de aprendizado supervisionado, não supervisionado e por reforço, sistemas baseados em IA analisam grandes volumes de dados em tempo real, identificam anomalias comportamentais e classificam ameaças com precisão superior aos métodos heurísticos tradicionais. Essa capacidade de aprendizado contínuo permite que os sistemas de defesa evoluam junto com as táticas dos atacantes [Varonis 2025].

O restante deste artigo está organizado da seguinte forma: a Seção 2 apresenta os fundamentos de IA aplicada à cibersegurança, descrevendo conceitos essenciais. A Seção 3 discute propostas baseadas em IA para aprimorar a detecção de ameaças e intrusões em ambientes cibernéticos. Na Seção 4 são analisadas as aplicações práticas e arquiteturas de defesa baseadas em IA, bem como os principais desafios e riscos relacionados. A Seção 5 apresenta os resultados e discussões, bem como as tendências e perspectivas futuras do uso de IA para solucionar problemas de cibersegurança. E, por fim, a Seção 6 traz a conclusão, sintetizando as principais análises e reflexões do estudo.

2. Conceitos Básicos

Esta seção vai descrever, de forma resumida, os principais conceitos que servem de base para compreender estratégias de detecção de ameaças.

2.1 Inteligência Artificial (IA)

A IA possibilita a criação de sistemas computacionais que permitem realizar atividades onde antes era necessário uma inteligência humana. Na cibersegurança, a IA é usada com o objetivo de possibilitar que sistemas de defesa possam se comportar de forma autônoma, como por exemplo identificando tráfegos anômalos em uma rede [Di Fatto 2025].

Conectada a área de IA, o ML tem como foco principal fazer com que sistemas entendam padrões através de uma base de dados. Para isso há a utilização de algoritmos como regressão linear e K-means, que permitem os sistemas tomar decisões e se aprimorarem utilizando dados gerados por cada iteração [Fateme e Abadi 2023].

Como subtipo da área de ML temos o aprendizado supervisionado e o não supervisionado. No supervisionado algoritmo é treinado com dados que estão rotulados com indicação para o que aquele dado significa, o que ajuda a mapear as entradas para as saídas corretas. Já o aprendizado não supervisionado, aborda os dados de forma não rotulada, tendo como a ideia central é identificar padrões [Monard e Baranauskas 2003].

2.2 Ameaças cibernéticas modernas

As ameaças cibernéticas estão evoluindo constantemente nos quesitos de sofisticação e escala, tornando cada vez mais necessário abordagens de defesas igualmente avançadas. Os parágrafos a seguir detalham algumas dessas ameaças modernas.

O Malware polimórfico, através da mudança de assinatura digital em tempo de execução, impede que algum antivírus que se baseia em assinaturas de malware já conhecidas possa impedi-lo. Ele utiliza um motor de polimorfismo para gerar uma ofuscação de código, ocasionando em um código compilado diferente, com outro tipo de assinatura [Elsevier 2022].

Também se encaixam nessa categoria de ameaças modernas os ataques de zero-day que consistem na exploração de vulnerabilidades desconhecidas, para as quais não há assinaturas de detecção ou correções documentadas no momento do ataque, dificultando sua identificação e mitigação por soluções de segurança tradicionais [Sarhan *et al.* 2023].

Outro tipo de ameaça moderna é o ataque de negação de serviço distribuído (DDoS), esse tipo de ataque tem como objetivo tornar algum serviço ou algum recurso da rede indisponível, sobrecarregando a rede com um volume massivo de tráfego através de várias máquinas comprometidas [Barreto 2023].

2.3 Arquiteturas de defesa baseadas em IA

As arquiteturas de defesa baseadas em IA representam um avanço significativo aos modelos tradicionais, permitindo a criação de sistemas mais adaptativos com o uso de múltiplos componentes inteligentes com a capacidade de encontrar, detectar, analisar e responder ameaças em tempo real.

Os modelos *multilayer* são estratégias de defesa que utilizam múltiplas camadas de segurança, onde cada camada utiliza diferentes técnicas de IA para analisar o tráfego e o comportamento em diversos pontos da infraestrutura da rede [Rosana *et al.* 2023].

Já o *zero trust architecture (ZTA)* é um tipo de arquitetura que funciona sobre o princípio fundamental do “privilegio mínimo”, a ideia é assumir que nenhum usuário dentro ou fora da rede é confiável e conceder acesso somente após realizar uma série de verificações do que cada pessoa realmente necessita ou pode acessar [Ajish 2024].

2.4 Desafios críticos na IA para segurança

Alguns obstáculos podem impactar a confiabilidade da implementação de sistemas de defesa com IA, como o Adversarial Machine Learning, onde atacantes podem criar entradas específicas para enganar modelos de IA. Além disso, o viés de dados em seu treinamento pode gerar um sistema de defesa não confiável que gera diversos falsos positivos [Elsevier 2022]. Adicionados a isso, temos também os elevados níveis de requisitos computacionais para a implementação da IA o que torna necessário grandes investimentos para a implementação adequada em um ambiente corporativo.

3. Trabalhos relacionados

Os trabalhos relacionados a seguir examinam as principais estratégias de detecção de ataques, enfatizando suas aplicações em cenários práticos de segurança cibernética.

Barreto [Barreto 2023] desenvolveu um framework de detecção de intrusão em tempo real para ambientes IoT, utilizando aprendizado de máquina para identificar ataques de Negação de Serviço (DoS), como syn-flood. A arquitetura integra o *plugin* Wazuh para monitoramento e geração de alertas. Com isso, os eventos coletados são transformados em features que alimentam modelos de aprendizado, permitindo a classificação de padrões anômalos. Em contraste com métodos baseados em regras ou assinaturas, esta técnica demonstra maior robustez contra comportamentos não catalogados, oferecendo potencial para detecção de *zero-day*.

De forma análoga, Ribeiro *et al.* [Ribeiro *et al.* 2024] propõem uma solução para a detecção em tempo real focada em ataque DDoS. O sensor inteligente emprega ML para discernir padrões de tráfego anormais, examinando métricas que são convertidas em features destinadas a alimentar algoritmos de classificação. Os autores realizaram uma avaliação comparativa de modelos de aprendizado supervisionado com base em

desempenho, latência e taxa de falsos positivos, o que garantiu a identificação precisa de ataques distribuídos. O sistema demonstrou alta sensibilidade, baixa latência e eficiência operacional, características ideais para ambientes distribuídos que requerem intervenção rápida.

É relevante destacar que o aprendizado de máquina mitiga não apenas ataques técnicos, mas também ameaças de vulnerabilidade humana, como o phishing. O trabalho de Gomes *et al.* [Gomes e João 2025] utiliza o ML para analisar o feedback de participantes em um jogo educativo, aplicando-o no processamento dos dados em vez da detecção direta.

Gomes e João utilizam a ferramenta Amazon Comprehend, que utiliza algoritmos de Processamento de Linguagem Natural (NLP) para identificar os tópicos linguísticos dos textos enviados pelos usuários após as partidas. Esses dados analíticos refinam o treinamento, permitindo que o jogo se adapte às dificuldades reais, como falhas em identificar spear phishing. Assim, o ML permite personalizar treinamentos e orientar o design do jogo.

4. Análise das Abordagens de IA na Detecção e Prevenção de Ameaças Cibernéticas

Essa seção vai trazer uma análise crítica sobre as abordagens do uso da IA para a detecção e prevenção de ameaças cibernéticas.

4.1 Análise geral das abordagens existentes

As abordagens de IA aplicadas à segurança cibernética podem ser divididas em três categorias: aprendizado supervisionado, aprendizado não supervisionado e aprendizado por reforço. Cada abordagem vai apresentar características distintas, variando na precisão, dependência de dados e sua adaptabilidade.

O aprendizado supervisionado é amplamente utilizado em atividades de classificação de ameaças já conhecidas utilizando modelos como SVM, *Random Forest* e NLP para, por exemplo, a detecção de *phishing* e ameaças através da análise de logs [Monard e Baranauskas 2003]. A principal vantagem desse modelo é sua alta precisão quando há uma distribuição de dados para treinamento estável, seu lado negativo é que há uma dependência de uma base de dados rotulada, o que dificulta bastante a detecção de ameaças emergentes como algum *zero-day*.

O aprendizado não supervisionado é comum em sistemas de detecção de ameaças baseado em anomalias, utilizando modelos como *K-means* e DBSCAN . Através desse método de aprendizado é possível identificar padrões incomuns no tráfego da rede, acessos suspeitos ou alguma variação significativa no comportamento de um usuário em um ambiente virtual [Monard e Baranauskas 2003]. É vantajoso de ser utilizado para detecção de ameaças emergentes, porém há uma grande taxa de falsos

negativos gerados, especialmente em ambientes que já tem uma variabilidade de forma natural.

O aprendizado por reforço é muito útil para automação de respostas a incidentes através do treinamento de algum agente inteligente, permitindo-o saber interagir com o ambiente da melhor forma possível. Esse tipo de técnica é muito promissor para desenvolver *firewalls* “inteligentes”, porém há alguns desafios relacionados à complexidade do treinamento desses modelos, já que exige simulações realistas e há um grande risco de o modelo ter algum comportamento imprevisível e não adequado ao esperado [Monard e Baranauskas 2003].

Dessa forma, compreende-se que a diversidade entre essas três categorias reforça a importância de tomar decisões estratégicas para adoção de modelos e suas implementações em ambientes de produção.

4.2 Comparação das técnicas de Machine Learning

Diferentemente da Seção 4.1, o objetivo nesta é entender como essas abordagens se comportam em um ambiente real, levando em conta fatores como escalabilidade, manutenção dos modelos, taxas de erro e capacidade de resposta a novos tipos de ataque.

Em ambientes corporativos, o aprendizado supervisionado costuma ter um bom desempenho quando há uma grande quantidade de dados rotulados. Sua precisão costuma ser superior às outras abordagens, especialmente em sistemas de detecção de malware e filtros de phishing [Monard e Baranauskas 2003]. No entanto, os custos envolvidos para rotulação contínua e nas atualizações dos modelos são elevados, e a técnica acaba perdendo sua eficiência quando enfrenta ataques recentes ou com um comportamento ainda não rotulado na base de dados. Sua escalabilidade é boa, mas exige pipelines bem definidas de coleta e processamento de dados, o que nem todas as organizações possuem ou conseguem fornecer uma manutenção adequada.

O aprendizado não supervisionado vai se destacar em ambientes dinâmicos, como redes corporativas de alto tráfego e sistemas distribuídos em nuvem, onde o comportamento normal muda constantemente [Monard e Baranauskas 2003]. Ele possui vantagens ao identificar anomalias inéditas através da análise de padrões, incluindo possíveis ataques de *zero-day*. Porém, seu uso operacional tem uma limitação importante que é a alta taxa de falsos positivos, já que vai gerar um grande custo humano para analisar cada caso. Essa característica exige sistemas complementares de filtragem e correlação de eventos para reduzir o ruído. Em termos de custo computacional, muitas abordagens não supervisionadas vão demandar uma maior capacidade de processamento, especialmente algoritmos de clustering.

O aprendizado por reforço, ainda sendo pouco utilizado em ambientes de produção [Gabriel 2025], é bastante promissor como solução para sistemas de defesa

adaptativa. Sua capacidade de aprender políticas de resposta automática, otimizando ações ao longo do tempo, o torna um forte candidato para ser utilizado em firewalls inteligentes, sistemas de mitigação de DDoS e automação de respostas a intrusões. Apesar disso, sua adoção tem alguns desafios técnicos como o treinamento que vai requerer ambientes controlados capazes de simular ataques reais sem comprometer a operação, o treinamento tende a ser bastante demorado e o comportamento aprendido nem sempre é previsível. Em termos de maturidade, é o tipo de abordagem menos consolidada no mercado justamente pela necessidade de auditoria e rastreabilidade em ambientes corporativos.

Em resumo, cada abordagem tem seus pontos fortes e fracos. O método de ML possui ótimo desempenho e uma grande quantidade de dados rotulados. Por outro lado, o método não supervisionado, é mais adequado para detectar anomalias, enquanto o método por reforço fornece maior adaptabilidade, mesmo sendo menos robusto para utilização em larga escala. A tendência é que o uso de modelos híbridos com o objetivo de aumentar a capacidade dos sistemas de defesa cresça nos próximos anos.

4.3 Síntese das abordagens modernas

As arquiteturas inteligentes de defesa demonstram grande evolução diante do crescimento de ameaças cibernéticas, caracterizadas por serem de maior sofisticação, velocidade e capacidade de adaptação. Diferentemente dos modelos mais utilizados, baseados em assinaturas ou regras, elas integram mecanismos dinâmicos, capazes de aprender, prever e responder ameaças em cenários complexos. Essas arquiteturas combinam tecnologias como ML, análise comportamental, *threat intelligence* e sistemas distribuídos, que operam de forma coordenada em toda a infraestrutura da organização.

4.3.1 Modelos Multicamadas com IA

Entre as abordagens que compõem as “Arquiteturas Inteligentes” temos os modelos multicamadas baseados em IA, eles se destacam como uma abordagem eficaz para detecção de ameaças e análise de eventos em sistemas computacionais. Essa arquitetura combina, como em uma hierarquia, técnicas complementares como análise por assinaturas, métodos estatísticos, algoritmos de aprendizado de máquina e modelos de deep learning. Nas camadas iniciais, procedimentos de normalização e detecção por regras permitem identificar padrões já conhecidos. Em seguida, técnicas de aprendizado supervisionado e não supervisionado analisam o comportamento dos dados, detectam desvios e atividades anômalas que não seriam capturadas por métodos mais tradicionais. Por fim, modelos profundos, como redes neurais recorrentes, ampliam a capacidade de identificar relações de tempo e correlações complexas. A combinação dessas camadas tem como resultado um sistema mais adaptável, que reduz falsos positivos e identifica ataques zero-day com mais facilidade.

4.3.2 Zero Trust Architecture com IA

Outra aplicação relevante é a junção de IA ao paradigma de ZTA. Essa “união” tem ampliado a eficácia dos mecanismos de verificação ativos, controles de acesso e detecção de ameaças. Enquanto o ZTA assume que nenhum usuário ou dispositivo é confiável, a IA permite transformar isso em uma operação de forma dinâmica, analisando comportamento, contexto e padrões de uso em tempo real. Dessa forma, modelos de ML são utilizados para identificar desvios comportamentais, anomalias em autenticações, acessos incompatíveis com perfis de risco e tentativas de elevação de privilégios, possibilitando decisões adaptáveis de autorização ou bloqueio. Além disso, algoritmos de análise preditiva calculam a probabilidade de risco com base nos históricos, aumentando também a precisão das políticas de segmentação da rede. Logo, a combinação entre IA e ZTA é capaz de reduzir falsos positivos, acelerar respostas a incidentes, fortalecer a resiliência da infraestrutura e oferecer um nível de controle que seria inviável com métodos totalmente manuais ou estáticos.




Figura 1. Fluxo da arquitetura Zero Trust

4.4 Fragilidades

Apesar dos avanços proporcionados pela aplicação de IA na segurança da informação, diversas fragilidades ainda dificultam a eficácia e a confiabilidade dessas soluções. Um dos principais desafios é o AML, que consiste na manipulação das entradas do modelo para induzir classificações incorretas, explorando vulnerabilidades matemáticas das redes neurais e afetando decisões críticas.

Outro problema relevante é o viés de dados, que surge quando o conjunto de treinamento não representa adequadamente o ambiente real. Essa limitação compromete a qualidade e a confiabilidade dos modelos utilizados em cibersegurança, pois leva o sistema a aprender padrões distorcidos, reduzindo sua capacidade de generalização.

Como consequência, podem ocorrer falsas correlações, aumento de falsos positivos e decisões injustas ou inconsistentes por parte do algoritmo.

Destaca-se também a dificuldade em explicar modelos complexos, uma vez que muitas soluções baseadas em IA operam como black boxes, ou seja, apresentando resultados sem evidenciar o raciocínio que levou à decisão. Essa falta de transparência compromete a interpretação, dificulta auditorias e diminui a confiança dos administradores ao justificar ações de segurança.

Tais desafios evidenciam que, apesar de seu alto potencial, o uso de IA ainda demanda avanços significativos em robustez, mitigação de vieses e técnicas de explicabilidade para que possa ser aplicado de forma totalmente confiável no contexto da segurança cibernética.

5. Resultados e Discussões

A análise da literatura existente e a identificação das lacunas nas defesas cibernéticas tradicionais, conforme detalhado nas seções anteriores, permitem a extração de resultados e o estabelecimento de uma discussão crítica sobre o papel transformador da Inteligência Artificial (IA) na cibersegurança. Os trabalhos revisados e os fundamentos conceituais apresentados convergem para um resultado principal: a eficácia da IA reside na mudança de paradigma da segurança, passando da detecção baseada em assinaturas (reativa) para a detecção baseada em comportamento e anomalias (proativa).

Entre os principais benefícios e características comuns observados nos métodos de detecção de ameaças com IA, destacou-se a capacidade de adaptação contínua (sistemas de aprendizado de máquina Supervisionado e Não Supervisionado podem se aprimorar dinamicamente, ajustando-se a novas táticas de ataque, como variações de malware polimórfico), a detecção de Zero-Day e Ameaças Desconhecidas (o uso de técnicas de clustering e detecção de outliers permite identificar comportamentos que se desviam da linha de base normal de uma rede ou dispositivo, mesmo que o ataque seja inédito), a análise em tempo real e escala (a IA permite o processamento de grandes volumes de dados de rede em tempo real, fornecendo a velocidade e a escala necessárias para combater ataques distribuídos ambientes IoT massivos, conforme demonstrado pelas propostas que integram o stack ELK [Monard e Baranauskas 2003, Elsevier 2022]) e, por fim, a automação e otimização da resposta (a aplicação de IA na cibersegurança não se limita à detecção, mas também otimiza a resposta, seja automatizando o alerta ou fornecendo dados analíticos estruturados, reduzindo a latência crítica entre detecção e mitigação).

5.1 Discussão Crítica

Embora a IA represente a maior esperança para a cibersegurança, a adoção em larga escala enfrenta desafios críticos que podem ser resumidos em uma crise de confiança no modelo de defesa. O grande problema na área reside na vulnerabilidade dos próprios modelos de IA e na dificuldade de auditá-los em um ambiente de alto risco. A solução para a crise de confiança passa pelo desenvolvimento de modelos que sejam não apenas precisos, mas também robustos (resistentes ao AML) e explicáveis (passíveis de auditoria humana).

O problema da falta de *explicabilidade* (XAI) em modelos complexos de Deep Learning também representa um obstáculo à confiança. Em um ambiente de segurança, quando a IA sinaliza uma intrusão, o analista de segurança precisa saber o porquê e quais fatores levaram à decisão. Sem a XAI, a decisão do modelo é uma "caixa preta", dificultando a auditoria, a correção de erros e a defesa legal em caso de incidente. Esse é um dilema central: os modelos mais precisos (Redes Neurais Profundas) são frequentemente menos explicáveis.

5.2 Tendências Futuras

Diante dos avanços identificados na Seção 5, as tendências futuras apontam para soluções que buscam simultaneamente ampliar a eficácia dos modelos de IA e mitigar os fatores que comprometem sua confiabilidade e adoção. Assim, as direções emergentes da área refletem uma resposta direta tanto às capacidades já demonstradas pela IA quanto aos desafios estruturais que ainda impedem sua maturação plena no contexto da cibersegurança.

A IA Generativa, está sendo integrada à cibersegurança para além da detecção: modelos GenAI podem criar conjuntos de dados de malware ou tráfego de rede sintético de alta fidelidade para treinar modelos de detecção de forma mais robusta e cobrir cenários de baixa frequência (corner cases). Para além disso, LLMs estão sendo usados para automatizar a sumarização de relatórios de threat intelligence e a tradução de código suspeito, acelerando a fase de pesquisa de ameaças (Threat Hunting).

5.3.1 SOC's Inteligentes e Automação SOAR

A colaboração humano-máquina (Human-Machine Teaming) é o futuro dos Centros de Operações de Segurança (SOCs). A IA assume o papel de analista de Nível 1, realizando a triagem inicial e a correlação de eventos, enquanto o analista humano se concentra em investigações complexas. A IA impulsiona Plataformas SOAR (Security Orchestration, Automation, and Response) ao tomar decisões autônomas de resposta, como isolar um host infectado ou bloquear um endereço IP malicioso, em tempo real, sem intervenção humana.

Apesar do potencial transformador, a adoção plena de SOC's inteligentes enfrenta limitações práticas. A eficácia dos modelos depende, em grande parte, da

disponibilidade de grandes volumes de dados rotulados e atualizados, o que é um desafio em ambientes onde incidentes reais são raros ou sensíveis demais para compartilhamento. Além disso, sistemas SOAR ainda enfrentam dificuldades em generalizar comportamentos maliciosos em cenários altamente dinâmicos, podendo gerar ações autônomas imprecisas caso o contexto não seja corretamente interpretado. Esses fatores indicam que, embora a automação avançada seja promissora, o papel humano continua indispensável para supervisão, validação e ajuste contínuo das decisões automatizadas.

5.3.2 Ciber-resiliência e Arquiteturas Preditivas

A ênfase está migrando ao invés de apenas "prevenir" para "prevenir, detectar e se recuperar rapidamente". A Ciber-resiliência é a capacidade de um sistema de suportar um ataque e retornar rapidamente ao seu estado operacional. A IA é fundamental para automatizar a ZTA pois ela aplica o princípio do "privilegio mínimo" de forma dinâmica, reavaliando continuamente o risco de um usuário ou dispositivo. Se um comportamento anômalo for detectado, a IA pode revogar imediatamente o acesso (micro-segmentação dinâmica), garantindo que um ataque não se mova lateralmente pela rede.

Na prática, a integração entre IA e ZTA ocorre por meio de mecanismos de avaliação contínua de risco baseados em identidade, dispositivo e contexto. A IA monitora padrões de autenticação, variabilidade comportamental, postura de segurança do endpoint e anomalias no fluxo de comunicação, recalculando dinamicamente o nível de confiança atribuído a cada entidade. Caso um desvio significativo seja detectado, o sistema executa ações como reforço de autenticação, isolamento de sessão ou revalidação de permissões, aplicando o princípio do “nunca confiar, sempre verificar” em tempo real. Essa interação operacional torna a arquitetura Zero Trust mais responsiva e adaptativa, reduzindo significativamente o risco de movimentação lateral dentro da rede.

Por fim, observa-se um grande potencial nas pesquisas futuras em XAI, com o objetivo de construir modelos de IA que forneçam uma justificativa auditável para suas decisões, restaurando a confiança do analista e superando o desafio crítico da "caixa preta".

6. Conclusão e Trabalhos Futuros

Este artigo apresentou uma revisão abrangente sobre o uso de IA na detecção, prevenção e resposta a ameaças cibernéticas, destacando como técnicas de aprendizado de máquina transformam o paradigma tradicional da segurança da informação. Foram discutidos os fundamentos da IA aplicada à cibersegurança, as principais ameaças modernas, arquiteturas avançadas como modelos *multilayer*. Além disso, foram apresentados trabalhos relacionados que demonstram a eficácia prática de abordagens

supervisionadas, não supervisionadas e por reforço. A análise crítica realizada na Seção 4 reforçou que, embora a IA ofereça ganhos significativos em precisão, velocidade e escalabilidade, sua adoção exige consideração cuidadosa de limitações técnicas e operacionais.

A partir da Seção 3, observou-se que as abordagens baseadas em IA apresentam resultados consistentes na detecção proativa de ameaças, especialmente pela capacidade de adaptação contínua, análise comportamental e automação de respostas. Técnicas de aprendizado não supervisionado e deep learning demonstraram alta eficiência na identificação de ataques zero-day e anomalias em ambientes dinâmicos. Enquanto modelos supervisionados mantêm desempenho sólido quando há conjuntos de dados robustos e rotulados. Além disso, a integração de IA em arquiteturas consolidadas, como ZTA e sistemas SOAR, evidencia uma tendência crescente de automatizar processos de segurança e fortalecer a resiliência organizacional.

Apesar desses avanços, a pesquisa também identificou limitações importantes que comprometem a maturidade dessas soluções. O aprendizado adversarial permanece como uma das principais ameaças aos sistemas de detecção inteligentes, pois pequenas manipulações nos dados de entrada podem induzir classificações incorretas. Outra limitação significativa é o viés presente nos conjuntos de treinamento, que pode reduzir a generalização dos modelos e aumentar taxas de falsos positivos ou negativos. Por fim, foi visto que a falta de explicabilidade de técnicas avançadas de Deep Learning dificulta auditorias e reduz a confiança dos analistas, especialmente em ambientes de alto risco.

7. Referências

- BD Emerson. (2025) “Cybercrime Statistics 2025: Global Trends and Key Data”, <https://www.bdemerson.com/article/complete-cybercrime-statistics>.
- D Ajish. (2024) “The significance of artificial intelligence in zero trust technologies: a comprehensive review”. <https://doi.org/10.1186/s43067-024-00155-z>
- David Braue. (2025) “Cybercrime To Cost The World \$12.2 Trillion Annually By 2031”, <https://cybersecurityventures.com/official-cybercrime-report-2025/>.
- Di Fatto. (2025) “Aplicação de inteligência artificial na detecção de ameaças em redes de computadores”, https://revistadifatto.com.br/wp-content/uploads/pdfs_gerados/706_aplicacao-de-aplicacao-de-inteligencia-artificial-na-deteccao-de-ameacas-em-redes-de-computadores.pdf.
- Elsevier. (2022) “Deceiving AI-based malware detection through polymorphic attacks”, <https://www.sciencedirect.com/science/article/pii/S0166361522001488>
- Fatemeh Deldar, Mahdi Abadi. (2023) “Deep Learning for Zero-day Malware Detection and Classification: A Survey”, <https://doi.org/10.1145/3605775>

- Felipe Barreto. (2023) “Framework para detecção de ataques DOS em dispositivos IOT, utilizando abordagens de aprendizado de máquinas”, https://ppee.unb.br/wp-content/uploads/2023/07/Dissertacao_Felipe_Barreto.pdf
- Gabriel Boechat. (2025) “Análise da aplicação da inteligência artificial no atual cenário de cibersegurança”, <https://repositorio.uniceub.br/jspui/bitstream/prefix/17278/1/21650430.pdf>
- Gustavo Gomes, João Alkmin. (2025) “Gamificação e Inteligência artificial no combate ao phishing”, https://pesquisafatec.com.br/ojs/efatec/pt_BR/article/view/351
- Maria Carolina Monard, José Augusto Baranauskas. (2003) “Conceitos sobre Aprendizado de Máquina”, <https://dcm.ffclrp.usp.br/~augusto/publications/2003-sistemas-inteligentes-cap4.pdf>
- Ribeiro, Fonseca, Santi. (2024) “Um sensor baseado em Aprendizado de máquina para detecção de ataque DDoS em tempo real”
https://sol.sbc.org.br/index.php/sbrc_estendido/article/view/29959
- Rosana Nunes, Caio Bello, et al. (2023) “Inteligência Artificial e Aprendizado por Reforço”, <https://revista-cbtecle.cps.sp.gov.br/index.php/CBTecLE/article/view/1152>
- Sarhan, M., Layeghy, S., Gallagher, M. et al. (2023) “From zero-shot machine learning to zero-day attack detection”, <https://rdcu.be/eTdb8>.
- Varonis. (2025) “139 Cybersecurity Statistics and Trends [updated 2025]”, <https://www.varonis.com/blog/cybersecurity-statistics>.